

Однажды в Самарканде турист заказывал Яндекс-такси. На десятом заказе впервые приехал таксист, который уже раньше приезжал к туристу. Для упрощения предположим, что все  $n$  таксистов Самарканда всегда на работе и приезжают равновероятно.

а) [5] Постройте график функции правдоподобия как функции от общего количества такси  $n$ . Найдите оценку числа  $n$  методом максимального правдоподобия.

Вероятность того, что к туристу в Самарканде приедет впервые таксист, который уже раньше его возил:

$$P = \frac{n}{n} \frac{(n-1)}{n} \frac{(n-2)}{n} \dots \frac{(n-8)}{n} \frac{9}{n} \text{ Получается: } P = \frac{n!9}{(n-9)!n^{**10}}$$

In [346...


```
import numpy as np
import matplotlib.pyplot as plt

def likelihood(n):
    p = 1.0
    for i in range(9):
        p *= (n - i) / n
    p *= 9/n
    return p

n_values = np.arange(1, 1001)

likelihood_values = [likelihood(n) for n in n_values]
estimated_n = n_values[np.argmax(likelihood_values)]

plt.plot(n_values, likelihood_values, color='midnightblue')
plt.xlabel('Количество таксистов (n)')
plt.ylabel('Вероятность')
plt.title('График функции правдоподобия')
plt.grid(True)
plt.show()
```



```
In [349... # Найдём оценку числа n методом максимального правдоподобия
n_ml = np.argmax(likelihood_values)+1
print('ML оценка n = ', n_ml)
```

ML оценка n = 42


б) [5] Постройте график математического ожидания номера заказа, на котором происходит первый повторный приезд, как функции от общего количества такси  $n$ . Найдите оценку числа  $n$  методом моментов.

```
In [367... import numpy as np
import matplotlib.pyplot as plt

def expected_order(n):
    expected = 0.0
    for i in range(2, n+2):
        p = 1
        for j in range(i-1):
            p *= (n - j) / n
        expected += i*(i-1)*p/n
    return expected

n_values = np.arange(1, 1001)
expected_values = [expected_order(n) for n in n_values]

plt.plot(n_values, expected_values)
plt.xlabel('Количество такси, n')
plt.ylabel('Мат. ожидание номера заказа')
plt.title('Математическое ожидание номера заказа от количества такси')
plt.grid(True)
plt.show()
```



```
In [369... n_MM = expected_values.index(min(expected_values, key=lambda x: abs(x - 10)))  
print(f'ММ оценка для количества таксистов = {n_MM}')
```

ММ оценка для количества таксистов = 55

в) Предположим, что настоящее  $n$  равно 100. Проведя 10000 симуляций вызовов такси до первого повторного, рассчитайте 10000 оценок методом моментов и 10000 оценок методом максимального правдоподобия. Постройте гистограммы для оценок двух методов. Оцените смещение, дисперсию и среднеквадратичную ошибку двух методов.

```

In [476... import numpy as np
import matplotlib.pyplot as plt

def simulate_calls(n, num_simulations):
    calls_to_repeat = []
    for _ in range(num_simulations):
        drivers = set()
        calls = 0
        while True:
            calls += 1
            driver = np.random.randint(1, n + 1)
            if driver in drivers:
                calls_to_repeat.append(calls)
                break
            drivers.add(driver)
    return calls_to_repeat

n = 100
num_simulations = 10000
calls_to_repeat = simulate_calls(n, num_simulations)

moments_estimate = np.mean(calls_to_repeat)
likelihood_estimate = np.log(n) + np.log(1 - 1 / n) * np.mean(calls_to_repeat)

true_value = n
bias_moments = moments_estimate - true_value
bias_likelihood = likelihood_estimate - true_value


variance_moments = np.var(calls_to_repeat)
variance_likelihood = np.var(calls_to_repeat)

mse_moments = bias_moments**2 + variance_moments
mse_likelihood = bias_likelihood**2 + variance_likelihood

plt.hist(calls_to_repeat, bins='auto', alpha=0.7, label='Simulated Calls')
plt.xlabel('Число вызовов')
plt.ylabel('Частота')
plt.legend()
plt.show()

print("Метод моментов:")
print("Смещение:", bias_moments)
print("Дисперсия:", variance_moments)
print("MSE:", mse_moments)
print()
print("Метод максимального правдоподобия:")
print("Смещение:", bias_likelihood)
print("Дисперсия:", variance_likelihood)
print("MSE:", mse_likelihood)

```



Метод моментов:

Смещение:  $-86.76859999999999$

Дисперсия:  $39.08705404$

MSE:  $7567.876999999999$

Метод максимального правдоподобия:

Смещение:  $-95.52780982782393$

Дисперсия:  $39.08705404$

MSE:  $9164.649504540894$

Что-то не так, как будто((

## Task 2

Однажды в Самарканде турист заказывал Яндекс-такси. На десятом заказе он обнаружил, что у таксистов было 6 разных имён. Для упрощения предположим, что все  $n$  имён среди таксистов встречаются равновероятно и независимо от поездки к поездке.

а) Постройте график функции правдоподобия как функции от общего количества имён  $n$ . Найдите оценку числа  $n$  методом максимального правдоподобия.

```
In [410... image_path = "/Users/linalalan/Downloads/photo_2023-06-11_22-57-02 (2).jpg"
image = Image.open(image_path)

display(image)
```

$$E(y_i) = \beta F_i \quad y_i - \text{результат за экзамен}$$

$$[a] \hat{\beta}_{MM} = ?$$

$$E(y_i) = \beta F_i$$

$$E(y_i | F_i) = \beta F_i$$

$$E(E(y_i | F_i)) = \beta E(F_i)$$

$$E(y_i) = \beta E(F_i)$$

$$\begin{aligned} E(y_i) &= \bar{y} \\ E(F_i) &= \bar{F} \end{aligned} \Rightarrow \begin{aligned} \bar{y} &= \beta \bar{F} \\ \hat{\beta}_{MM} &= \bar{y} / \bar{F} \end{aligned}$$

```
In [411... from scipy.optimize import minimize

def likelihood(n, k, m):
    return ((n - k) / n) ** m

def maximize_likelihood(k, m):
    objective = lambda x: -likelihood(x[0], k, m) # Минус, так как использую
    initial_guess = [k+2] # Начальное приближение для оптимизации
    bounds = [(k, None)] # Ограничение на значение n (k и больше)
    result = minimize(objective, initial_guess, bounds=bounds)
    return result.x[0]

k = 6 # количество разных имен
m = 10 # общее количество поездок

estimated_n = maximize_likelihood(k, m)
print(f"Оценка числа n: {estimated_n}")
```


Оценка числа  $n$ : 8.0

```
In [429... def likelihood(n):
    likelihood_value = 0
    for k in range(1, 11):
        likelihood_value += comb(10, k) * (1/(n+1e-10))**k * (1-1/(n+1e-10))
    return likelihood_value

# comb(10, k) - вычисляет количество возможных комбинаций из 10 элементов, k
# (1/(n+1e-10))**k - вероятность того, что конкретное имя встретится k раз с
# (1-1/(n+1e-10)) - вероятность того, что остальные имена (не выбранное конк
# (1/(n+1e-10)**10) - вероятность, что каждое из общего количества поездок п
# Везде, где число/n добавила что-то маленькое: 1e-10, чтобы он не ругался,

n_values = np.arange(6, 1000)
likelihood_values = [likelihood(n) for n in n_values]

plt.plot(n_values, likelihood_values)
plt.xlabel('Количество имён (n)')
plt.ylabel('Функция правдоподобия')
plt.title('Функция правдоподобия как функция от количества имён')
plt.grid(True)
plt.show()
```





## Task 3

Иноагент Иннокентий по 20 наблюдениям строит 95%-й доверительный интервал для математического ожидания несколькими способами: классический асимптотический нормальный интервал, с помощью наивного бутстрэпа, с помощью бутстрэпа t-статистики.

### A

Для каждого способа с помощью 10000 симуляций оцените вероятность того, что номинально 95%-й доверительный интервал фактически покрывает математическое ожидание, если наблюдения распределены экспоненциально с интенсивностью 1.

```
In [82]: import numpy as np
from scipy.stats import expon, norm, t
import scipy.stats as sts
```

```
In [ ]: n_sim = 10000
sample = 20
confidence = 0.95
alpha = 0.05
```

```
In [37]: data = expon.rvs(scale=1, size=(n_sim, sample), random_state=42)
```

### Способ 1: классический асимптотический нормальный интервал

```
In [46]: count = 0

#Проходим циклом по всем симуляциям
for i in data:
    mean = np.mean(data, axis=1) #находим среднее
    std = np.std(data, axis=1, ddof=1) / np.sqrt(sample) #находим стандартную
    z_critical = np.abs(norm.ppf((1 - confidence) / 2))
    ci_normal = np.column_stack((mean - z_critical * std, mean + z_critical

mu = 1 # Фактическое математическое ожидание

coverage_normal = np.mean((ci_normal[:, 0] <= mu) & (mu <= ci_normal[:, 1]))
print('Вероятность, что 95%-ый доверительный интервал фактически покрывает м
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.904

## Способ 2: наивный бутстрэп

```
In [72]: np.random.seed(42)

# Количество генерируемых бутстрэпом выборок
n_boot = 10000

covering_boot = 0
# Проход циклом по всем симуляциям
for i in data:
    boot_i = np.random.choice(i, size=(n_boot, sample))
    boot_i_mean = np.mean(boot_i, axis=1)
    q_L, q_R = np.quantile(boot_i_mean, alpha/2), np.quantile(boot_i_mean, 1-alpha/2)
    CI = [q_L, q_R]

    if (CI[0] <= mu) & (mu <= CI[1]):
        covering_boot += 1

print('Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.903')
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.903

## Способ 3: бутстрэп t-статистики

```
In [78]: np.random.seed(42)

covering_boot_t = 0

for i in data:
    boot_i = np.random.choice(i, size=(n_boot, len(i)))
    R_boot_t = (np.mean(boot_i, axis=1) - np.mean(i)) / (np.std(boot_i, ddof=1))
    CI_boot_t = [
        np.mean(i) - np.quantile(R_boot_t, 1 - 0.05 / 2) * (np.std(i, ddof=1)),
        np.mean(i) + np.quantile(R_boot_t, 0.05 / 2) * (np.std(i, ddof=1))
    ]

    if (CI_boot_t[0] <= mu) and (mu <= CI_boot_t[1]):
        covering_boot_t += 1

print('Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.947')
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.947

Б

Пересчитайте вероятности накрытия, если наблюдения имеют распределение Стьюдента с тремя степенями свободы.

```
In [139...] data = t.rvs(df=3, size=(n_sim, sample), random_state=42)
```

### Способ 1: классический асимптотический нормальный интервал

```
In [145...] count = 0

#Проходим циклом по всем симуляциям
for i in data:
    mean = np.mean(data, axis=1) #находим среднее
    std = np.std(data, axis=1, ddof=1) / np.sqrt(sample) #находим стандартну
    z_critical = np.abs(norm.ppf((1 - confidence) / 2))
    ci_normal = np.column_stack((mean - z_critical * std, mean + z_critical

mu = 0 # Фактическое математическое ожидание (поменялось, тк распределение

coverage_normal = np.mean((ci_normal[:, 0] <= mu) & (mu <= ci_normal[:, 1]))
print('Вероятность, что 95%-ый доверительный интервал фактически покрывает м
    round(coverage_normal, 3))
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.944

### Способ 2: наивный бутстрэп

```
In [146...] np.random.seed(42)

# Количество генерируемых бутстрэпом выборок
n_boot = 10000

covering_boot = 0
# Проход циклом по всем симуляциям
for i in data:
    boot_i = np.random.choice(i, size=(n_boot, sample))
    boot_i_mean = np.mean(boot_i, axis=1)
    q_L, q_R = np.quantile(boot_i_mean, alpha/2), np.quantile(boot_i_mean, 1
    CI = [q_L, q_R]

    if (CI[0] <= mu) & (mu <= CI[1]):
        covering_boot += 1

print('Вероятность, что 95%-ый доверительный интервал фактически покрывает м
    round(covering_boot/n_boot, 3))
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.919

### Способ 3: бутстрэп t-статистики

```
In [147... np.random.seed(42)

covering_boot_t = 0

for i in data:
    boot_i = np.random.choice(i, size=(n_boot, len(i)))
    R_boot_t = (np.mean(boot_i, axis=1) - np.mean(i)) / (np.std(boot_i, ddof=1)
    CI_boot_t = [
        np.mean(i) - np.quantile(R_boot_t, 1 - 0.05 / 2) * (np.std(i, ddof=1)
        np.mean(i) - np.quantile(R_boot_t, 0.05 / 2) * (np.std(i, ddof=1) /

    ]

    if (CI_boot_t[0] <= mu) and (mu <= CI_boot_t[1]):
        covering_boot_t += 1

print('Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: ',
      round(covering_boot_t / n_boot, 3))
```

Вероятность, что 95%-ый доверительный интервал фактически покрывает математическое ожидание: 0.923

## В

Какой способ оказался лучше?

В случае с экспоненциальным распределением, оказался лучше метод бутстрэп t-статистики (накрытие мат ожидания - 0.047). В случае с распределением Стюдента - классический асимптотический нормальный интервал (накрытие мат ожидания - 0.923).

## Task 4

Проверьте гипотезу о том, что ожидаемые результаты экзамена по теории вероятностей тех, у кого фамилия начинается с гласной буквы и с согласной буквы, равны. В качестве альтернативной гипотезы возьмите гипотезу о неравенстве.

```
In [148... import numpy as np
import pandas as pd
```

```
In [243... df = pd.read_csv('/Users/linalalan/Downloads/Copy of 22-23_hse_probability - df
```

Out [243]:

	num	Last name	Name	Экзамен
0	1	Репенкова	Полина Александровна	16
1	2	Ролдугина	Софья Александровна	0
2	3	Сафина	Алия Линаровна	19
3	4	Сидоров	Иван Максимович	26
4	5	Солоухин	Иван Владимирович	21
...	...	...	...	...
327	328	Сенников	Александр -	19
328	329	Ся	Юйцянь -	0
329	330	Сятова	Альфия -	0
330	331	Темиркулов	Дастан Автандилович	0
331	332	Эшмеев	Павел Владиславович	16

332 rows x 4 columns

```
In [244... missing_values = df.isna().sum()
missing_values
```

```
Out [244]: num      0
Last name  0
Name      0
Экзамен    0
dtype: int64
```

а) [5] Используйте тест Уэлча.

```
In [249... import scipy.stats as stats

# Разделение данных на две группы
def vowel(word):
    vowels = 'АЯУЮОЕЁЭИЫ'
    return word[0].upper() in vowels
= df[df['Last name'].apply(vowel)].reset_index(drop=True)
consonant_group = df[~df['Last name'].apply(vowel)].reset_index(drop=True)

# Тест Уэлча
_, p_value = stats.ttest_ind(vowel_group['Экзамен'], consonant_group['Экзамен'])

alpha = 0.05
if (p_value > alpha/2) & (p_value <= (1 - alpha/2)):
    print("Не отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена равны.")
else:
    print("Отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена различаются.")

print('p-value = ', round(p_value, 3))
```

Не отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена равны.  
p-value = 0.397

б) [5] Используйте наивный бутстрэп.

```
In [261... np.random.seed(42)
vowel_boot = np.random.choice(vowel_group['Экзамен'], size=(n_sim, len(vowel_group['Экзамен'])))
cons_boot = np.random.choice(consonant_group['Экзамен'], size=(n_sim, len(consonant_group['Экзамен'])))

# Посчитаем разницу средних на выборке и на бутстрапированных данных
delta = np.mean(vowel_group['Экзамен']) - np.mean(consonant_group['Экзамен'])
delta_boot = np.mean(vowel_boot, axis=1) - np.mean(cons_boot, axis=1)

# Считаем p_value, как долю бутстрапированных разниц средних, превышающих разницу в выборке
p_value = np.mean(delta_boot >= delta)

if p_value > alpha/2 and pvalue < (1 - alpha/2):
    print("Не отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена равны.")
else:
    print("Отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена различаются.")
```

Не отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена равны.

в) [5] Используйте бутстрэп t-статистики.

```

In [275... vowel_results = vowel_group['Экзамен'].dropna()
consonant_results = consonant_group['Экзамен'].dropna()

# Определение статистики
observed_mean_diff = np.mean(vowel_results) - np.mean(consonant_results)

# Генерация бутстрэп выборок
num_iterations = 10000 # Количество итераций бутстрэпа (возьмем как обычно,
bootstrap_mean_diffs = np.zeros(num_iterations)

for i in range(num_iterations):
    vowel_indices = np.random.choice(len(vowel_results), size=len(vowel_resu
    consonant_indices = np.random.choice(len(consonant_results), size=len(cc

    bootstrap_vowel_results = vowel_results[vowel_indices]
    bootstrap_consonant_results = consonant_results[consonant_indices]

    bootstrap_mean_diffs[i] = np.mean(bootstrap_vowel_results) - np.mean(boc

# Вычисление p-значения
p_value = (np.abs(bootstrap_mean_diffs) >= np.abs(observed_mean_diff)).mean(

alpha = 0.05 # Уровень значимости
if p_value < alpha:
    print("Не отвергаем нулевую гипотезу: средние ожидаемые результаты экзамен
else:
    print("Отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена
print(p_value)

```

Отвергаем нулевую гипотезу: средние ожидаемые результаты экзамена не равны.  
0.5391

г) [5] Используйте перестановочный тест.

```
In [277... observed_mean_diff = np.mean(vowel_results) - np.mean(consonant_results)
all_results = np.concatenate([vowel_results, consonant_results])
num_permutations = 10000

perm_mean_diffs = np.zeros(num_permutations) # Для хранения перестановочных

for i in range(num_permutations):
    permuted_labels = np.random.permutation(all_results)

    perm_vowel_results = permuted_labels[:len(vowel_results)]
    perm_consonant_results = permuted_labels[len(vowel_results):]

    perm_mean_diffs[i] = np.mean(perm_vowel_results) - np.mean(perm_consonant_results)

p_value = (np.abs(perm_mean_diffs) >= np.abs(observed_mean_diff)).mean()

alpha = 0.05
if p_value < alpha:
    print("Отвергаем нулевую гипотезу. Ожидаемые результаты экзамена различны")
else:
    print("Не отвергаем нулевую гипотезу. Ожидаемые результаты экзамена равны")
print(p_value)
```

Не отвергаем нулевую гипотезу. Ожидаемые результаты экзамена равны для групп с фамилиями, начинающимися с гласной и согласной буквы.

0.3812

В каждом случае укажите Р-значение и статистический вывод для уровня значимости 5%.

## Task 5

Составьте таблицу сопряжённости, поделив студентов писавших экзамен на четыре группы по двум признакам: набрал ли больше медианы или нет, на согласную или гласную букву начинается фамилия. В качестве альтернативной гипотезы используйте гипотезу о неравенстве

```
In [306... median = df['Экзамен'].median()

vow_more_med = (vowel_group['Экзамен'] > median).sum()
vow_less_med = (vowel_group['Экзамен'] < median).sum()
cons_more_med = (consonant_group['Экзамен'] > median).sum()
cons_less_med = (consonant_group['Экзамен'] < median).sum()

# Создаём таблицу сопряжённости
table = pd.DataFrame({'Less': [vow_less_med, cons_less_med], 'More': [vow_more_med, cons_more_med]})
table
```



Out [306]:

	Less	More
Vowel	28	21
Consonant	138	145

## A

Постройте 95% асимптотический интервал для отношения шансов хорошо написать экзамен («несогласных» к «согласным»). Проверьте гипотезу о том, что отношение шансов равно 1 и укажите Р-значение.

In [304...

```
from PIL import Image
from IPython.display import display

image_path = "/Users/linalalan/Downloads/photo_2023-06-11_20-02-18.jpg"
image = Image.open(image_path)

display(image)
```

Less More

Var. 28 21

Cons. 138 145

$$\text{Odds} = \frac{p}{1-p}; \text{ тогда отношение шансов: } OR = \frac{p_{\text{var.}}/(1-p_{\text{var.}})}{p_{\text{cons.}}/(1-p_{\text{cons.}})}$$

$$\ln OR = \ln \frac{p_{\text{var.}}}{1-p_{\text{var.}}} - \ln \frac{p_{\text{cons.}}}{1-p_{\text{cons.}}}$$

Дельта-метод.

$$\frac{\partial f(\hat{p})}{\partial \hat{p}} = \frac{1}{1-\hat{p}} \cdot \left( \frac{1}{1-\hat{p}} \right) = \frac{1-\hat{p}}{\hat{p}}; \hat{p} - \text{асимптотически нормальное распр}$$

$$\text{var} \left( \frac{\partial f(\hat{p})}{\partial \hat{p}} \right) \approx \left( \frac{\partial f(\hat{p})}{\partial \hat{p}} \right)^2 \cdot \text{Var}(\hat{p})$$

Разложение дельта-метода:

$$f(\hat{p}) \approx f(p) + \left( \frac{\partial f(p)}{\partial p} \right) (\hat{p} - p) \Rightarrow \ln \left( \frac{\hat{p}}{1-\hat{p}} \right) \approx \ln \left( \frac{p}{1-p} \right) + \frac{1-p}{p} (\hat{p} - p)$$

Ищем мат. ожид. и дисп.:

$$E \left( \ln \frac{\hat{p}}{1-\hat{p}} \right) = \ln \frac{p}{1-p}$$

$$\text{Var} \left( \ln \frac{\hat{p}}{1-\hat{p}} \right) \approx \left( \frac{1}{(1-p)p} \right)^2 \cdot \text{Var}(\hat{p}) = \frac{p(1-p)}{(1-p)^2 p^2 \cdot n} = \frac{1}{(1-p)p \cdot n}$$

$$E(\ln \hat{OR}) \approx \ln \frac{p_{\text{var.}}}{1-p_{\text{var.}}} - \ln \frac{p_{\text{cons.}}}{1-p_{\text{cons.}}}$$

$$\text{Var}(\ln \hat{OR}) \approx \frac{1}{(1-p_{\text{var.}}) p_{\text{var.}} \cdot n_{\text{var.}}} + \frac{1}{(1-p_{\text{cons.}}) p_{\text{cons.}} \cdot n_{\text{cons.}}}$$

$$se(\hat{OR}) = \sqrt{\frac{1}{(1-p_{\text{var.}}) p_{\text{var.}} \cdot n_{\text{var.}}} + \frac{1}{(1-p_{\text{cons.}}) p_{\text{cons.}} \cdot n_{\text{cons.}}}}$$

Или найдем все, что нужно, чтобы DV:

$$\text{где } \ln OR: \ln \hat{OR} \pm 1.96 \cdot se(\ln \hat{OR}); \ln \hat{OR} \pm 1.96 se(\ln \hat{OR})$$

$$\text{где } OR: \hat{OR} \cdot e^{-1.96 \cdot se(\ln \hat{OR})}; \hat{OR} \cdot e^{1.96 \cdot se(\ln \hat{OR})}$$

```
In [313... p_vow = vow_more_med/vow_less_med
p_cons = cons_more_med/cons_less_med
OR = p_vow/p_cons

se_or = np.sqrt(1/vow_more_med + 1/vow_less_med + 1/cons_more_med + 1/cons_l
z = stats.norm.ppf(0.975)

lower_border = OR*np.exp(-z * se_or)
upper_border = OR*np.exp(z * se_or)

test_stat = np.log(OR) / se_or
p_value = sts.norm.cdf(test_stat, loc=0, scale=1)
print('Нижняя граница: ', round(lower_border, 2))
print('Верхняя граница: ', round(upper_border, 2))
print('p-value: ', round(p_value, 2))
```

```
Нижняя граница: 0.39
Верхняя граница: 1.32
p-value: 0.14
```

Нет оснований отвергать гипотезу о том, что отношение шансов равно 1.

## Б

Постройте 95% асимптотический интервал для отношения вероятностей хорошо написать экзамен. Проверьте гипотезу о том, что отношение вероятностей равно 1 и укажите Р-значение.

```
In [314... image_path = "/Users/linalalan/Downloads/photo_2023-06-11_21-36-13.jpg"
image = Image.open(image_path)

display(image)
```

Подход, аналогичный предельным рискам:

$$RR = \frac{p_{row}}{p_{cons}}; \quad \ln RR = \ln p_{row} - \ln p_{cons}.$$

$$\frac{\partial \ln(\hat{p})}{\partial \hat{p}} = \frac{1}{\hat{p}}; \quad \text{Var}\left(\frac{\partial \ln \hat{p}}{\partial \hat{p}}\right) \approx \left(\frac{1}{\hat{p}}\right)^2 \cdot \text{var}(\hat{p})$$

$$\ln \hat{p} \approx \ln p + \left(\frac{\partial \ln p}{\partial p}\right) (\hat{p} - p)$$

$$\ln \hat{p} \approx \ln p + \frac{1}{p} (\hat{p} - p)$$

$$E(\ln \hat{p}) = \ln p$$

$$\text{Var}(\ln \hat{p}) = \left(\frac{1}{p}\right)^2 \cdot \text{Var}(\hat{p}) = \frac{p \cdot (1-p)}{p^2 \cdot n} = \frac{1-p}{p \cdot n}$$

$$E(\ln \hat{RR}) = \ln p_{row} - \ln p_{cons}.$$

$$\text{Var}(\ln \hat{RR}) \approx \frac{1-p_{row}}{p_{row} \cdot n_{row}} - \frac{1-p_{row}}{p_{cons} \cdot n_{cons}}.$$

$$se(\ln \hat{RR}) \approx \sqrt{\frac{1-p_{row}}{p_{row} \cdot n_{row}} - \frac{1-p_{row}}{p_{cons} \cdot n_{cons}}}$$

$$2U: \ln \hat{RR} - 1.96 \cdot se(\ln \hat{RR}); \ln \hat{RR} + 1.96 \cdot se(\ln \hat{RR})$$

$$2Ue RR: \hat{RR} \cdot e^{-1.96 \cdot se(\ln \hat{RR})}; \hat{RR} \cdot \exp(1.96 \cdot se(\ln \hat{RR}))$$

```
In [321... p_vow_ver = vow_more_med/(vow_more_med+vow_less_med)
p_cons_ver = cons_more_med/(cons_more_med+cons_less_med)
ratio = p_vow_ver/p_cons_ver

se_ver = np.sqrt(vow_less_med/(vow_more_med * (vow_more_med + vow_less_med))
                + cons_less_med/(cons_more_med * (cons_more_med + cons_less_med)))

lower_border = ratio*np.exp(-z * se_ver)
upper_border = ratio*np.exp(z * se_ver)

ezhik = np.log(ratio) / np.sqrt(1/vow_more_med + 1/vow_less_med + 1/cons_more_med + 1/cons_less_med)
p_value = sts.norm.cdf(ezhik, loc=0, scale=1)

print('Нижняя граница: ', round(lower_border, 2))
print('Верхняя граница: ', round(upper_border, 2))
print('p-value: ', round(p_value, 2))
```

```
Нижняя граница:  0.59
Верхняя граница:  1.18
p-value:  0.28
```

Нет оснований отвергать гипотезу о том, что отношение вероятностей равно 1.

## В

Постройте 95% интервал для отношения шансов хорошо написать экзамен с помощью наивного бутстрэпа. Проверьте гипотезу о том, что отношение шансов равно 1 и укажите Р-значение.

```

In [329... np.random.seed(42)

p_vow = vow_more_med / vow_less_med
p_cons = cons_more_med / cons_less_med

OR = p_vow / p_cons

n_bootstrap = 10000

bootstrap_OR = np.zeros(n_bootstrap) #Массив для хранения

for i in range(n_bootstrap):
    vowel_bootstrap_sample = vowel_group.sample(frac=1, replace=True)
    consonant_bootstrap_sample = consonant_group.sample(frac=1, replace=True)

    p_vow_bootstrap = (vowel_bootstrap_sample['Экзамен'] > median).sum() / (
    p_cons_bootstrap = (consonant_bootstrap_sample['Экзамен'] > median).sum() / (
    bootstrap_OR[i] = p_vow_bootstrap / p_cons_bootstrap

se_or = np.sqrt(1 / vow_more_med + 1 / vow_less_med + 1 / cons_more_med + 1 / cons_less_med)

z = stats.norm.ppf(0.95)

lower_bound = np.percentile(bootstrap_OR, 2.5)
upper_bound = np.percentile(bootstrap_OR, 97.5)

p_value = np.mean(bootstrap_OR >= OR)

print('Нижняя граница: ', round(lower_bound, 3))
print('Верхняя граница: ', round(upper_bound, 3))
print('p-value: ', round(p_value, 3))

Нижняя граница: 0.367
Верхняя граница: 1.33
p-value: 0.504

```

Нет оснований отвергать гипотезу о том, что отношение шансов равно 1.

## Task 6

Иноагент Иннокентий Вероятностно-Статистический считает, что длина фамилии положительно влияет на результат экзамена по теории вероятностей. А именно, он предполагает, что ожидаемый результат за экзамен прямо пропорционален длине фамилии,  $E(Y_i) = \beta F_i$ , где  $Y_i$  — результат за экзамен по 30-балльной шкале,  $F_i$  — количество букв в фамилии.

а) Оцените  $\beta$  методом моментов. Рассчитайте выборочную корреляцию.

```
In [330... image_path = "/Users/linalalan/Downloads/photo_2023-06-11_22-57-02.jpg"
image = Image.open(image_path)

display(image)
```

$E(y_i) = \beta F_i$      $y_i$  - результат за экзамен

[a]  $\hat{\beta}_{MM} = ?$

$$E(y_i) = \beta F_i$$

$$E(y_i | F_i) = \beta F_i$$

$$E(E(y_i | F_i)) = \beta E(F_i)$$

$$E(y_i) = \beta E(F_i)$$

$$\begin{aligned} E(y_i) &= \bar{y} \\ E(F_i) &= \bar{F} \end{aligned} \Rightarrow \begin{aligned} \bar{y} &= \beta \bar{F} \\ \hat{\beta}_{MM} &= \bar{y} / \bar{F} \end{aligned}$$

```
In [332... df['Last name length'] = df['Last name'].apply(len) # Вычисление длины фамилий
beta_hat = df['Экзамен'].mean() / df['Last name length'].mean() # Считаем оценку
print('Оценка методом моментов = ', round(beta_hat, 2))
```

Оценка методом моментов = 2.06

```
In [335... # Вычисление выборочной корреляции
corr_bobr = df['Экзамен'].corr(df['Last name length'])
print('Выборочная корреляция = ', round(corr_bobr, 3))
```

Выборочная корреляция = 0.025

б) С помощью перестановочного теста найдите Р-значение и формально протестируйте гипотезу о том, что корреляция равна нулю.

Гипотезы:

H0: Корреляция между результатом экзамена и длиной фамилии равна нулю.

H1: Корреляция между результатом экзамена и длиной фамилии не равна нулю.

```
In [337... # Вычисление наблюдаемого значения статистики
observed_corr = corr_bobr

# Перестановочный тест
num_permutations = 10000 # Берем как обычно, 10 000
permuted_corrs = np.zeros(num_permutations)

for i in range(num_permutations):
    permuted_exam_scores = np.random.permutation(df['Экзамен'])

    # Вычисление корреляции для перестановочной выборки
    permuted_corr = np.corrcoef(permuted_exam_scores, df['Last name length'])
    permuted_corrs[i] = permuted_corr

p_value = (np.abs(permuted_corrs) >= np.abs(observed_corr)).mean()

print('P-value =', p_value)
```

P-value = 0.6498

p-value > alpha, нет оснований отвергать нулевую гипотезу

## Task 7

С помощью chatgpt решите любую задачу из нашего курса теории вероятностей и статистики. Можно брать задачи из прошлых контрольных, лекций, семинаров и даже этого домашнего задания. В качестве ответа приведите полный диалог с chatgpt.

Простой диалог в виде двух реплик условия и ответа chatgpt даёт 6 баллов. Сложный диалог с наводками, указанием chatgpt на ошибки и их исправлением — 10 баллов.

Для случайной величины  $X$ , имеющей функцию плотности  $f(x) = (1/\sqrt{2\pi})e^{-(x^2)/2}$  вычислите центральный момент порядка 2011.

## ChatGPT

Центральный момент порядка  $k$  для случайной величины  $X$  с функцией плотности  $f(x)$  вычисляется следующим образом:



$$\mu_k = E[(X - E[X])^k],$$

где  $E[X]$  - математическое ожидание случайной величины  $X$ .

В данном случае у нас есть функция плотности, которая соответствует стандартному нормальному распределению. Для стандартного нормального распределения математическое ожидание равно нулю, т.е.,  $E[X] = 0$ .

Таким образом, нам нужно вычислить  $\mu_{2011}$ .

Учитывая, что  $E[X] = 0$ , центральный момент порядка 2011 примет следующий вид:

$$\mu_{2011} = E[X^{2011}].$$

Однако вычислить этот момент в явном виде не является тривиальной задачей.

Мы можем попробовать найти моменты нижних порядков и найти закономерности, которые помогут нам вычислить центральный момент порядка 2011. Однако в данном случае этот процесс может быть сложным и требовать использования специальных математических методов.

Таким образом, точный расчёт центрального момента порядка 2011 для данной функции плотности может потребовать специализированных математических инструментов или численных методов.

**User**

можно заметить, что функция плотности симметрична относительно нуля

**ChatGPT**

Да, вы правы. Функция плотности, которую вы предоставили, является функцией плотности стандартного нормального распределения. Известно, что стандартное нормальное распределение является симметричным относительно нуля.

Таким образом, центральные моменты нечетных порядков для стандартного нормального распределения равны нулю. Это означает, что центральный момент порядка 2011 для данной функции плотности также будет равен нулю:

$$\mu_{2011} = 0.$$

**User**

молодец!

## ChatGPT

Спасибо! Я рад, что смог помочь. Если у вас возникнут еще вопросы, не стесняйтесь задавать их. Я всегда готов помочь!

Задача из первой КР 2011-2012 года

## Task 8

1. Укажите любой источник по теории вероятностей или статистике, который вам оказался полезен в течение года. Это может быть статья, видео, задача, всё что угодно. Объясните, с чем конкретно этот источник помог разобраться. Лучше привести в пример внешний источник, не упомянутый на вики курса, но можно и внутренний.
- Учебник Борzych Д.А. "Математическая статистика в задачах" и часть 1. Учебник для "чайников (как я)", там объясняется все очень подробно с нуля + примеры. По нему я ботала первые две контрольные и помню, что просто так читала, когда не могла осознать отличия распределений и их особенности. Именно на интуитивном уровне не хватало понимания, а этот учебник очень помог. + там есть разборы задачек, некоторые из них даже на КР встречались. Ссылки нет, есть pdf версия только (там вообще две части, я читала только первую).
  - Лекции от CSC: <https://www.youtube.com/watch?v=I3k0YcONPvg&list=PLIb7e2G7aSpRliB5S5ld-3nxxVAH5cyAc>. Увидела в свое время в Поступашках. Обращалась, когда не до конца поняла тему про проверку гипотез.

In [ ]: